

Zela+ — Relatório do Trabalho Final (Agentes de IA)

Autor: Lucas Augusto Repositório: (link do GitHub a ser preenchido na entrega do card) Vídeo pitch: ver docs/pitch/roteiro.md para o roteiro; o arquivo de vídeo fica em docs/pitch/zela-pitch.mp4 no repositório.

1. Descrição do projeto

1.1 Problema

Idosos que moram sozinhos enfrentam três riscos recorrentes que motivaram este projeto, a partir de um caso real (avó do autor, que mora sozinha):

1. Esquecimento de medicação e compromissos — sem alguém por perto para lembrar, doses e consultas são perdidas.
2. Falta de detecção precoce de risco — uma queda, uma ausência de movimento prolongada, ou uma alteração de sinais vitais pode passar despercebida por horas.
3. Família fora do loop — parentes que não moram junto não têm visibilidade do dia a dia (a medicação foi tomada? está tudo bem hoje?) sem ligar toda hora, o que é cansativo para os dois lados.

1.2 Oportunidade e escopo do MVP


O escopo mínimo viável do Zela+ cobre as três dores acima com o menor conjunto de funcionalidades que já demonstra valor de ponta a ponta:

- Lembretes de medicamentos/compromissos via WhatsApp, com confirmação pelo próprio idoso.
- Monitoramento de risco combinando sensores reais (presença via ESP32, sinais vitais via smartwatch) e a interpretação de mensagens de texto do idoso (classificadas por similaridade de embeddings).
- Uma escada de escalonamento determinística (nunca decidida por um LLM) que avisa a família e, em último caso, simula contato com um serviço de emergência.
- Um painel Streamlit para a família acompanhar status, medicação, alertas e um histórico de presença, além de cadastrar/editar medicamentos e compromissos.
- Um fluxo visual (n8n) que demonstra separadamente a lógica de classificação de urgência de uma mensagem, item explicitamente pedido pelo card (o curso migrou de Langflow para n8n — ver nota na seção 3.4).

Ficou fora do escopo do MVP (documentado como trabalho futuro): transcrição de áudio (STT/TTS) nas mensagens de WhatsApp, autenticação robusta nos endpoints internos, e um piso de confiança mínimo no classificador de urgência por similaridade — ver seção 6.

2. Arquitetura do agente/sistema multiagente

O Zela+ usa uma arquitetura de 5 agentes especializados, orquestrados pelo Google ADK, cada um com responsabilidade única e um contrato de dados Pydantic próprio:



Decisão de design mais importante do projeto: a decisão de escalonar uma emergência (avisar a família, simular contato de emergência) nunca é tomada por um LLM. Ela é calculada por uma máquina de estados determinística e pura (`zela/domain/emergencia.py` + `zela/storage/escalonamento.py`), testada exaustivamente com `pytest`. Os agentes de IA (inclusive o classificador de urgência por embeddings) apenas alimentam essa máquina com eventos (`EventoMonitoramento`) — a decisão de agir sobre um evento de risco é sempre determinística e auditável, nunca uma alucinação do modelo.

2.1 Papel de cada agente

Agente	Responsabilidade	Ferramentas (tools ADK)
Orquestrador (<code>orquestrador_zela</code>)	Direciona cada mensagem ao agente especializado certo	— (<code>sub_agents</code>)
Rotina/Medicação	Lembretes de medicamentos/compromissos, registra confirmações	<code>verificar_lembretes_pendentes</code> , <code>confirmar_medicamento</code>
Monitoramento de Saúde/Risco	Relata o status já calculado (normal/atenção/risco)	<code>consultar_status_atual</code>
Comunicação	Conversa com idoso/família, busca RAG em bulas e mensagens passadas	<code>consultar_conhecimento</code>

Agente	Responsabilidade	Ferramentas (tools ADK)
Emergência/Alertas	Relata alertas e ocorrências já registrados	consultar_historico_alertas

Nenhum agente decide sozinho um estado de risco ou dispara um alerta real — todos consultam ferramentas que refletem cálculos já feitos pela camada de domínio (*zela/domain/*), pura e testável sem LLM nem rede.

2.2 Fluxo de ponta a ponta (exemplo)

1. Hora de um remédio → Agente de Rotina dispara lembrete → Agente de Comunicação envia a mensagem via WhatsApp ao idoso.
2. Idoso confirma por WhatsApp → Orquestrador registra a confirmação.
3. Em paralelo, o Agente de Monitoramento consome leituras do smartwatch e do ESP32 (a cada 15 min) e mensagens de texto do idoso (classificadas por embeddings), gerando um status: `normal` / `atenção` / `risco`.
4. `atenção` → aviso à família via Streamlit/histórico de alertas.
5. `risco` → escalonamento determinístico: contato com o idoso → família → simulação de contato de emergência.
6. A família consulta o Streamlit a qualquer momento.

3. Detalhamento técnico

3.1 Validação de dados com Pydantic (card 3.3)

Todos os dados que entram no sistema — leituras de sensor, mensagens de WhatsApp, cadastro de medicamentos, perfil do idoso — são validados por modelos Pydantic antes de tocar qualquer lógica de negócio:

- *zela/models/perfil.py* — `PerfilIdoso`, `ContatoFamiliar`
- *zela/models/rotina.py* — `Medicamento`, `Dosagem`, `Compromisso`, `ConfirmacaoMedicacao` (com validação de que `data_hora` de um compromisso não pode estar no passado na criação)
- *zela/models/monitoramento.py* — `LeituraSensor`, `EventoMonitoramento`, além dos enums `StatusMonitoramento` (`normal/atenção/risco`), `MetodoClassificacao`
- *zela/models/alertas.py* — `Alerta`, com os enums `NivelAlerta`, `CanalAlerta`, `StatusAlerta`
- *zela/models/comunicacao.py* — `MensagemEntrada`, `TipoMensagem`

Um caso não-trivial de uso de Pydantic: o modelo `Compromisso` valida que a data não é passada na criação, mas ler um compromisso histórico do banco (já no passado, por definição) precisa contornar essa mesma validação — resolvido com `Compromisso.model_construct(...)` no caminho de leitura (*zela/storage/rotina.py::_linha_para_compromisso*), preservando a validação onde ela importa (escrita) sem quebrar a leitura de dados antigos.

3.2 Embeddings e RAG (card 3.5)

Duas aplicações de embeddings no MVP, ambas usando a API de embeddings do Gemini (*zela/embeddings/client.py*):

1. Classificação de urgência por similaridade (`zela/embeddings/classificador.py`): uma mensagem de texto do idoso (ex.: "caí no banheiro e não consigo levantar") é comparada por similaridade de cosseno contra 18 exemplos de referência rotulados em português (`zela/embeddings/exemplos_referencia.py`) e classificada como NORMAL / ATENCAO / RISCO pelo vizinho mais próximo. O resultado alimenta a mesma máquina de escalonamento usada pelos sensores — nunca decide um alerta sozinho.
2. RAG (Retrieval-Augmented Generation) sobre bulas de medicamentos cadastrados e o histórico de mensagens do idoso, usando um vector store Chroma local (`zela/embeddings/vetorial.py`). O Agente de Comunicação usa isso para responder perguntas como "para que serve esse remédio?" ou "o que a vó disse ontem?" sem inventar uma resposta quando não há contexto relevante.

Decisão de implementação notável: o cliente de embeddings (`ClienteEmbeddingGemini`) constrói o cliente real do Gemini de forma preguiçosa (só na primeira chamada, nunca no `__init__`) — isso permite importar o módulo em testes sem exigir uma chave de API configurada.

3.3 Orquestração multiagente com ADK (card 3.6)

A orquestração usa o Google Agent Development Kit (ADK): `zela/agents/orchestrator.py` define os 5 agentes da seção 2.1 como `google.adk.agents.Agent`, com o orquestrador registrando os 4 especializados como `sub_agents`. O roteamento entre eles é feito pelo próprio ADK a partir da `instruction` de cada agente — não há um roteador determinístico escrito à mão. As ferramentas (`tools`) de cada agente são funções Python puras que chamam a camada de armazenamento/domínio, nunca lógica de negócio direto no agente.

O comportamento pode ser verificado interativamente com `adk run zela/agents` (ver README, seção "Verificando o comportamento do agente").

3.4 Workflow n8n (card 3.4/3.8)

Nota sobre a ferramenta: o card original menciona Langflow; o curso migrou para n8n durante o desenvolvimento deste trabalho, então o fluxo visual foi implementado em n8n (`docs/n8n/zela-classificacao-mensagem.json`).

O workflow representa, de forma simplificada e visual, a fatia "mensagem recebida → classificação de urgência → roteamento" do sistema: um nó Webhook recebe a mensagem, um nó HTTP Request chama o endpoint real do backend (`POST /api/classificar-mensagem`, que reusa o mesmo classificador por embeddings da seção 3.2), e dois nós If encadeados roteiam a resposta para um de três nós de resposta (`alertar_familia` / `verificar_idosa` / `normal`) conforme o status retornado. Ele não substitui a integração real WhatsApp↔backend (que continua funcionando via WAHA, seção 3.6) — é uma demonstração visual isolada da lógica de classificação/roteamento, como pede o card.

(capturar após importar o workflow no n8n — instruções em `README.md`, seção "Workflow n8n (Plano 6)")

3.5 Interface de usuário com Streamlit (card 3.7)

O painel Streamlit (`zela/streamlit_app/`) é a interface da família: status atual, medicação do dia, histórico de alertas e um gráfico de presença (leitura, somente exibição), além de formulários para cadastrar/editar medicamentos e compromissos (escrita). Acesso protegido por senha (`STREAMLIT_SENHA`), com uma tela de erro amigável em vez de stack traces para qualquer seção que falhe.

Seção	Captura de tela
Status atual	
Medicação do dia	
Histórico de alertas	
Gráfico de presença	

(capturas a adicionar em docs/relatorio/imagens/ — instruções de como rodar o painel em README.md, seção "Painel Streamlit (Plano 5)")

3.6 Comunicação via WhatsApp (card 3.8)

A comunicação com o idoso e a família acontece via WhatsApp, integrada por meio do WAHA (WhatsApp HTTP API) — um webhook (`zela/api/webhook.py`) recebe mensagens recebidas pelo WAHA e as encaminha para o ADK Runner, que roteia ao agente apropriado; o cliente WAHA (`zela/integrations/waha_client.py`) envia as respostas de volta. Ver README para o passo a passo de configuração (Docker Compose + QR code + webhook).

4. Resultados obtidos

- 186 testes automatizados passando (`pytest -v`), cobrindo modelos Pydantic, lógica de domínio pura (rotina, monitoramento, emergência, comunicação), repositórios de armazenamento (SQLite), API (webhook, ingestão de sensores, classificação, scheduler), embeddings (classificador, cliente, vector store), orquestração ADK (nomes, hierarquia de sub-agentes, ferramentas) e o painel Streamlit (via `streamlit.testing.v1.AppTest`, execução real do script sem mocks).
- Todo o projeto foi construído em 6 fases sequenciais (planos), cada uma testável e mergeada independentemente: Fundação → Comunicação Real → Ingestão de Sensores → Embeddings → Painel Streamlit → Workflow n8n — este relatório documenta a fase final (empacotamento).
- A propriedade de segurança central do projeto — nenhuma decisão de escalonamento de emergência depende de um LLM — foi verificada repetidamente ao longo das 6 fases (incluindo revisões de código dedicadas a cada mudança que tocasse essa fronteira).
- Exemplo prático de funcionamento: uma mensagem do idoso como "caí no banheiro e não consigo levantar", enviada via WhatsApp ou testada via o workflow n8n, é classificada como RISCO pelo classificador de embeddings e alimenta a mesma escada de escalonamento usada pelos sensores (ver seção 6 para uma limitação conhecida sobre esse fluxo).

5. Instruções de uso

Resumo rápido — o README.md do repositório tem o passo a passo completo (instalação, configuração do WAHA, sensores, Streamlit e n8n):

```
python -m venv .venv
source .venv/bin/activate
pip install -e ".[dev]"
pytest -v # roda a suíte de 186 testes
uvicorn zela.api.main:app --reload # backend (webhook, API, scheduler)
streamlit run zela/streamlit_app/app.py # painel da família
```

Para o comportamento real dos agentes (com chamadas de verdade ao Gemini), configuração do WAHA/WhatsApp, ingestão de sensores (ESP32/Health Connect) e importação do workflow n8n, ver as seções correspondentes no README.md.

6. Limitações conhecidas e trabalhos futuros

Documentadas em detalhe no README.md ("Limitações conhecidas do Plano N"); resumo das mais relevantes:

1. Um risco originado por uma mensagem de texto não avança sozinho até a família — só o job periódico de sensores avança a escada de escalonamento adiante; corrigir exige persistir o evento que originou o escalonamento.
2. O classificador de urgência por similaridade não tem um piso mínimo de confiança — uma mensagem fora do padrão dos exemplos de referência ainda recebe a classificação do vizinho mais próximo.
3. Sessão de conversa do ADK Runner é única por idoso, não por remetente (idoso e família compartilham o mesmo histórico de contexto do LLM).
4. Sem autenticação nos endpoints internos (/ingest/*, /api/classificar-mensagem, /webhook/whatsapp) — aceitável para um MVP local, mas necessário antes de qualquer exposição além da rede doméstica.
5. Transcrição de áudio (STT/TTS) no WhatsApp ainda não implementada — hoje a comunicação é só por texto.

Essas limitações foram descobertas e documentadas durante o próprio desenvolvimento (revisões de código dedicadas ao final de cada fase), não depois da entrega — refletem prioridades conscientes de escopo de um MVP de 6 fases, não lacunas não percebidas.

7. Vídeo pitch

Roteiro cena a cena em docs/pitch/roteiro.md. Arquivo final em docs/pitch/zela-pitch.mp4.