Zela+ — Relatório do Trabalho Final (Agentes de IA)

Autor: Lucas Augusto Repositório: https://github.com/augustolnb/ag-zela- Vídeo pitch: ver `docs/pitch/roteiro.md` para o roteiro; o arquivo de vídeo fica em `docs/pitch/zela-pitch.mp4` no repositório.

---

1. Descrição do projeto

1.1 Problema

Idosos que moram sozinhos enfrentam três riscos recorrentes que motivaram este projeto, a partir de um caso real (avó do autor, que mora sozinha):

1. Esquecimento de medicação e compromissos — sem alguém por perto para lembrar, doses e consultas são perdidas.
2. Falta de detecção precoce de risco — uma queda, uma ausência de movimento prolongada, ou uma alteração de sinais vitais pode passar despercebida por horas.
3. Família fora do loop — parentes que não moram junto não têm visibilidade do dia a dia (a medicação foi tomada? está tudo bem hoje?) sem ligar toda hora, o que é cansativo para os dois lados.

1.2 Oportunidade e escopo do MVP

O escopo mínimo viável do Zela+ cobre as três dores acima com o menor conjunto de funcionalidades que já demonstra valor de ponta a ponta:

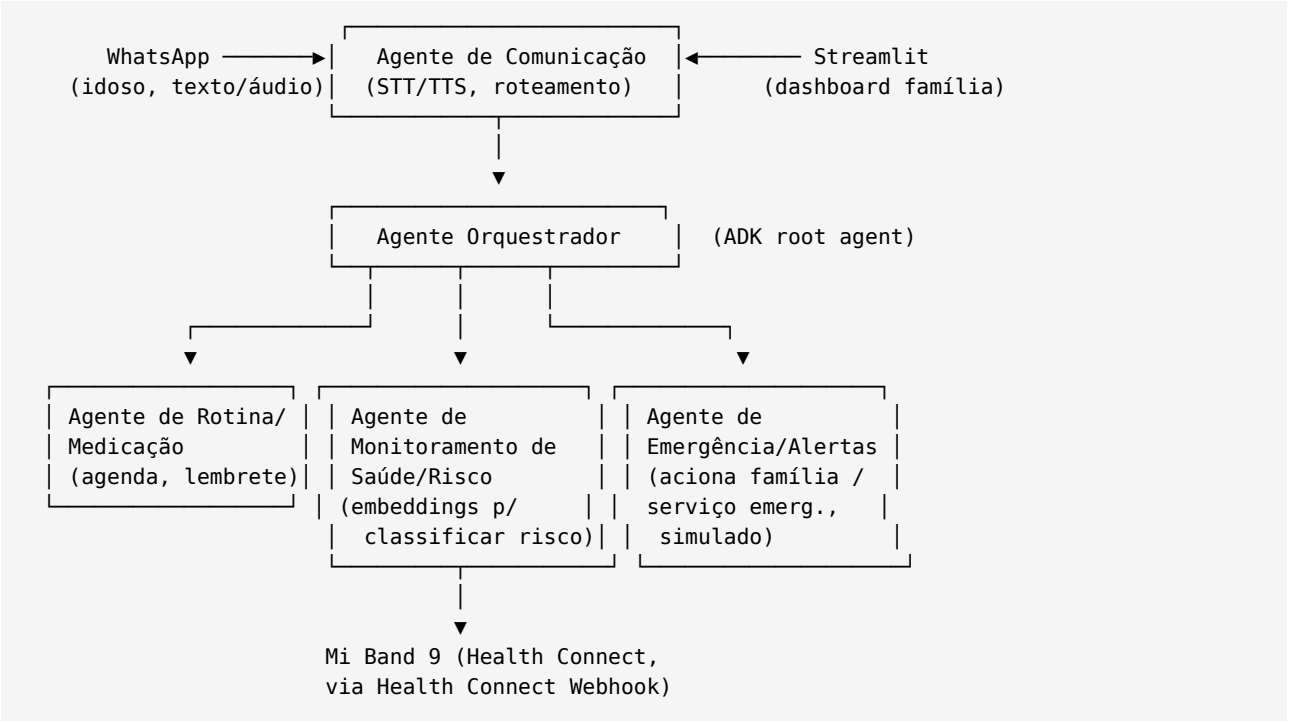
- Lembretes de medicamentos/compromissos via WhatsApp, com confirmação pelo próprio idoso.
- Monitoramento de risco combinando sinais vitais reais via smartwatch (Mi Band, via Health Connect) e a interpretação de mensagens de texto do idoso (classificadas por similaridade de embeddings).
- Uma escada de escalonamento determinística (nunca decidida por um LLM) que avisa a família e, em último caso, simula contato com um serviço de emergência.
- Um painel Streamlit para a família acompanhar status, medicação, alertas e um histórico de presença, além de cadastrar/editar medicamentos e compromissos.
- Um fluxo visual (n8n) que demonstra separadamente a lógica de classificação de urgência de uma mensagem, item explicitamente pedido pelo card (o curso migrou de Langflow para n8n — ver nota na seção 3.4).

Ficou fora do escopo do MVP (documentado como trabalho futuro): transcrição de áudio (STT/TTS) nas mensagens de WhatsApp, autenticação robusta nos endpoints internos, e um piso de confiança mínimo no classificador de urgência por similaridade — ver seção 6.

---

2. Arquitetura do agente/sistema multiagente

O Zela+ usa uma arquitetura de 5 agentes especializados, orquestrados pelo Google ADK, cada um com responsabilidade única e um contrato de dados Pydantic próprio:



Decisão de design mais importante do projeto: a decisão de escalonar uma emergência (avisar a família, simular contato de emergência) nunca é tomada por um LLM. Ela é calculada por uma máquina de estados determinística e pura (`zela/domain/emergencia.py` + `zela/storage/escalonamento.py`), testada exaustivamente com `pytest`. Os agentes de IA (inclusive o classificador de urgência por embeddings) apenas alimentam essa máquina com eventos (`EventoMonitoramento`) — a decisão de agir sobre um evento de risco é sempre determinística e auditável, nunca uma alucinação do modelo.

2.1 Papel de cada agente

Agente	Responsabilidade	Ferramentas (tools ADK)
Orquestrador (`orquestrador_zela`)	Direciona cada mensagem ao agente especializado certo	— (`sub_agents`)
Rotina/Medicação	Lembretes de medicamentos/compromissos, registra confirmações	`verificar_lembretes_pendentes`, `confirmar_medicamento`
Monitoramento de Saúde/Risco	Relata o status já calculado (normal/atenção/risco)	`consultar_status_atual`
Comunicação	Conversa com idoso/família, busca RAG em bulas e mensagens passadas	`consultar_conhecimento`
Emergência/Alertas	Relata alertas e ocorrências já registrados	`consultar_historico_alertas`

Nenhum agente decide sozinho um estado de risco ou dispara um alerta real — todos consultam ferramentas que refletem cálculos já feitos pela camada de domínio (`zela/domain/`), pura e testável sem LLM nem rede.

2.2 Fluxo de ponta a ponta (exemplo)

1. Hora de um remédio → Agente de Rotina dispara lembrete → Agente de Comunicação envia a mensagem via WhatsApp ao idoso.
2. Idoso confirma por WhatsApp → Orquestrador registra a confirmação.
3. Em paralelo, o Agente de Monitoramento consome leituras do smartwatch (a cada 15 min) e mensagens de texto do idoso (classificadas por embeddings), gerando um status: `normal` / `atenção` / `risco`.
4. `atenção` → aviso à família via Streamlit/histórico de alertas.
5. `risco` → escalonamento determinístico: contato com o idoso → família → simulação de contato de emergência.
6. A família consulta o Streamlit a qualquer momento.

---

3. Detalhamento técnico

3.1 Validação de dados com Pydantic (card 3.3)

Todos os dados que entram no sistema — leituras de sensor, mensagens de WhatsApp, cadastro de medicamentos, perfil do idoso — são validados por modelos Pydantic antes de tocar qualquer lógica de negócio:

- `zela/models/perfil.py` — `PerfilIdoso`, `ContatoFamiliar`
- `zela/models/rotina.py` — `Medicamento`, `Dosagem`, `Compromisso`, `ConfirmacaoMedicacao` (com validação de que `data_hora` de um compromisso não pode estar no passado na criação)
- `zela/models/monitoramento.py` — `LeituraSensor`, `EventoMonitoramento`, além dos enums `StatusMonitoramento` (normal/atenção/risco), `MetodoClassificacao`
- `zela/models/alertas.py` — `Alerta`, com os enums `NivelAlerta`, `CanalAlerta`, `StatusAlerta`
- `zela/models/comunicacao.py` — `MensagemEntrada`, `TipoMensagem`

Um caso não-trivial de uso de Pydantic: o modelo `Compromisso` valida que a data não é passada na criação, mas ler um compromisso histórico do banco (já no passado, por definição) precisa contornar essa mesma validação — resolvido com `Compromisso.model_construct(...)` no caminho de leitura (`zela/storage/rotina.py::_linha_para_compromisso`), preservando a validação onde ela importa (escrita) sem quebrar a leitura de dados antigos.

3.2 Embeddings e RAG (card 3.5)

Duas aplicações de embeddings no MVP, ambas usando a API de embeddings do Gemini (`zela/embeddings/client.py`):

1. Classificação de urgência por similaridade (`zela/embeddings/classificador.py`): uma mensagem de texto do idoso (ex.: "caí no banheiro e não consigo levantar") é comparada por similaridade de cosseno contra 18 exemplos de referência rotulados em português (`zela/embeddings/exemplos_referencia.py`) e classificada como `NORMAL` / `ATENCAO` / `RISCO` pelo vizinho mais próximo. O resultado alimenta a mesma máquina de escalonamento usada pelos sensores — nunca decide um alerta sozinho.

2. RAG (Retrieval-Augmented Generation) sobre bulas de medicamentos cadastrados e o histórico de mensagens do idoso, usando um vector store Chroma local (`zela/embeddings/vetorial.py`). O Agente de Comunicação usa isso para responder perguntas como "para que serve esse remédio?" ou "o que a vó disse ontem?" sem inventar uma resposta quando não há contexto relevante.

Decisão de implementação notável: o cliente de embeddings (`ClienteEmbeddingGemini`) constrói o cliente real do Gemini de forma preguiçosa (só na primeira chamada, nunca no `__init__`) — isso permite importar o módulo em testes sem exigir uma chave de API configurada.

3.3 Orquestração multiagente com ADK (card 3.6)

A orquestração usa o Google Agent Development Kit (ADK): `zela/agents/orchestrator.py` define os 5 agentes da seção 2.1 como `google.adk.agents.Agent`, com o orquestrador registrando os 4 especializados como `sub_agents`. O roteamento entre eles é feito pelo próprio ADK a partir da `instruction` de cada agente — não há um roteador determinístico escrito à mão. As ferramentas (`tools`) de cada agente são funções Python puras que chamam a camada de armazenamento/domínio, nunca lógica de negócio direto no agente.

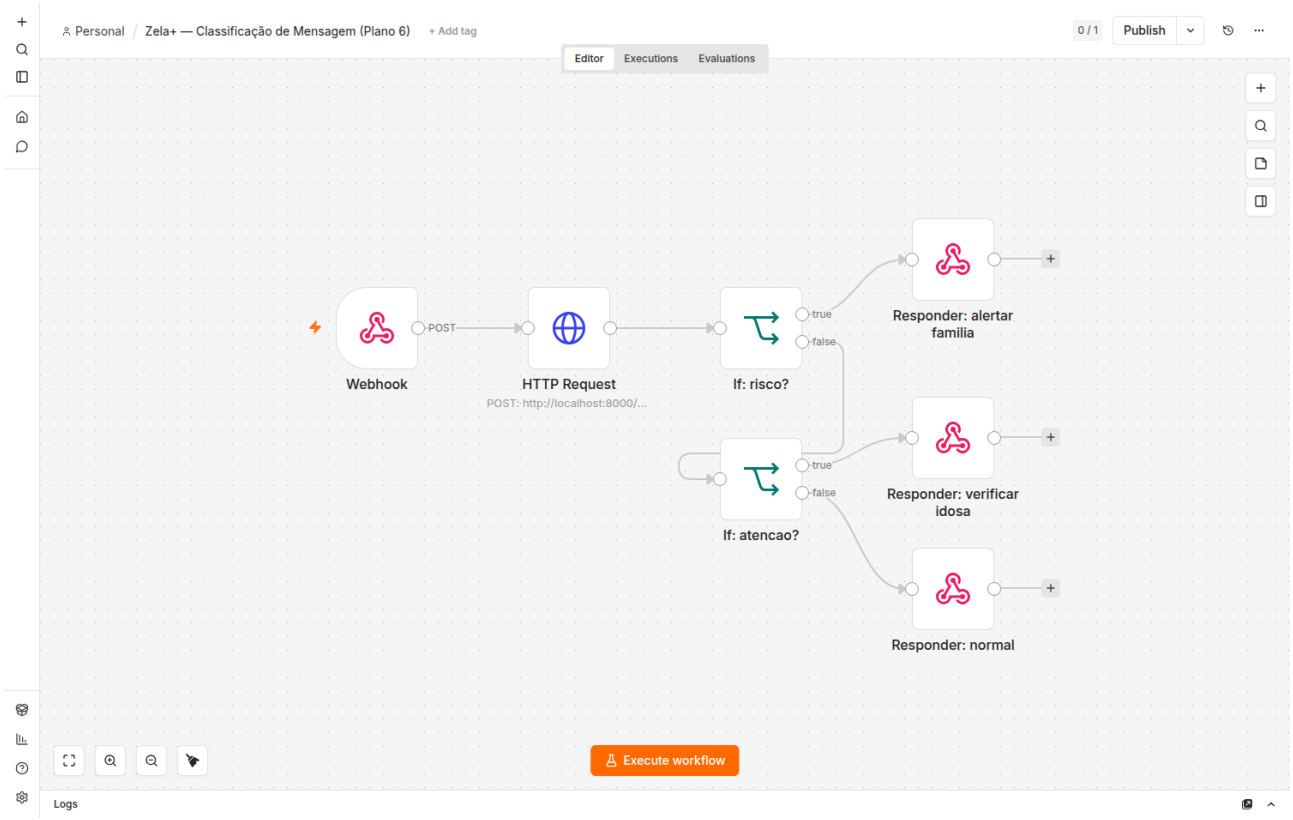
O comportamento pode ser verificado interativamente com `adk run zela/agents` (ver README, seção "Verificando o comportamento do agente").

LLM de conversação/orquestração: configurável via `ZELA_LLM_PROVEDOR` — padrão Gemini (`gemini-3.8-flash`), com DeepSeek (`deepseek-chat`, via `LiteLlm`) como alternativa. Na VPS de produção, o provedor ativo é o DeepSeek: o Gemini no tier gratuito tem limite de 5 requisições por minuto, insuficiente para mensagens em sequência rápida (confirmado na prática — ver seção 6, item 7), e o Gemini fica como reserva, fácil de reativar trocando uma variável de ambiente. Os embeddings (classificação de urgência e RAG, seção 3.2) continuam usando o Gemini independente dessa variável.

3.4 Workflow n8n (card 3.4/3.8)

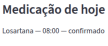
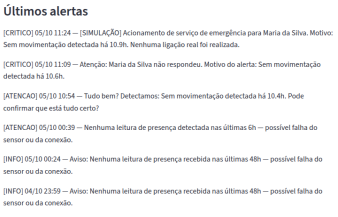
Nota sobre a ferramenta: o card original menciona Langflow; o curso migrou para n8n durante o desenvolvimento deste trabalho, então o fluxo visual foi implementado em n8n (`docs/n8n/zela-classificacao-mensagem.json`).

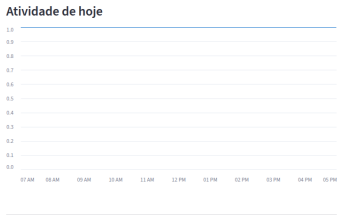
O workflow representa, de forma simplificada e visual, a fatia "mensagem recebida → classificação de urgência → roteamento" do sistema: um nó Webhook recebe a mensagem, um nó HTTP Request chama o endpoint real do backend (`POST /api/classificar-mensagem`, que reusa o mesmo classificador por embeddings da seção 3.2), e dois nós `If` encadeados roteiam a resposta para um de três nós de resposta (`alertar_familia` / `verificar_idosa` / `normal`) conforme o status retornado. Ele não substitui a integração real WhatsApp↔backend (que continua funcionando via WAHA, seção 3.6) — é uma demonstração visual isolada da lógica de classificação/roteamento, como pede o card.



3.5 Interface de usuário com Streamlit (card 3.7)

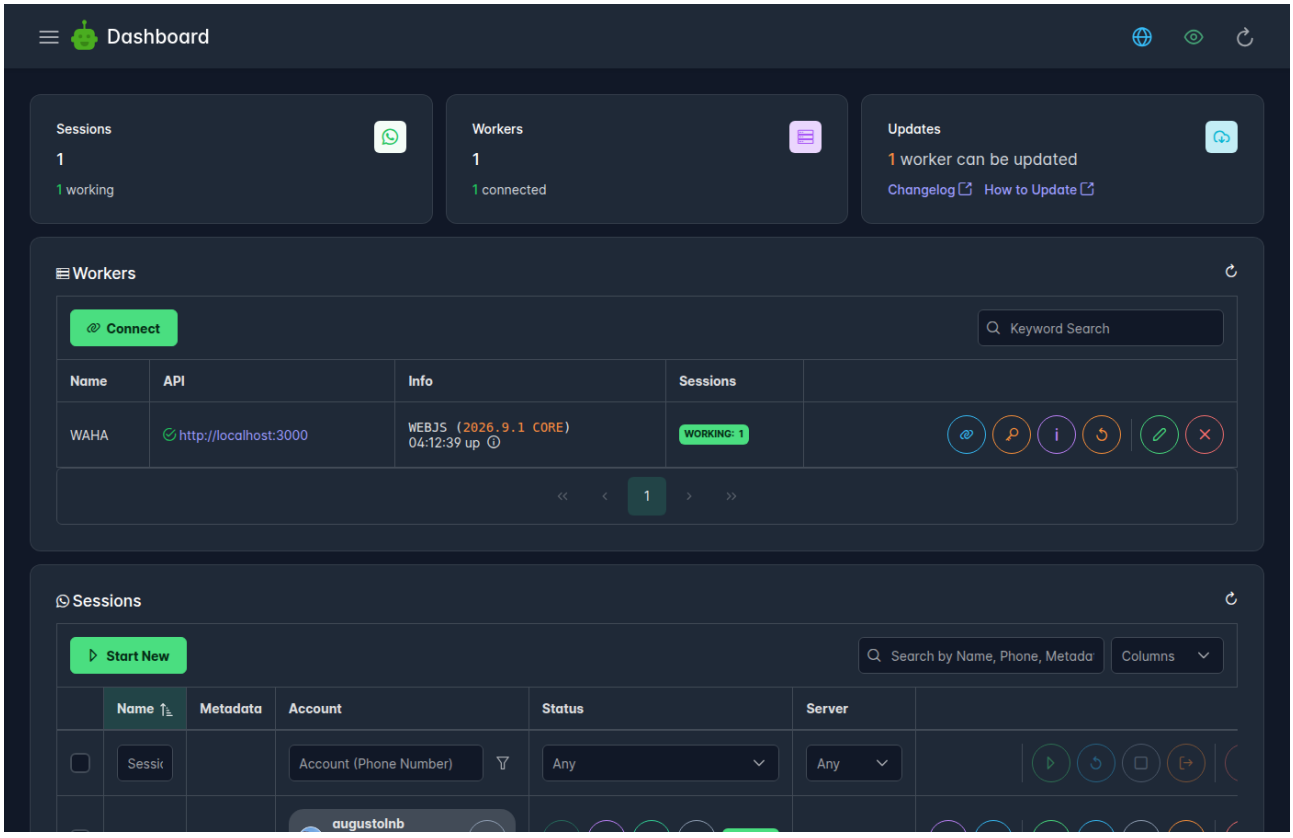
O painel Streamlit (`zela/streamlit_app/`) é a interface da família: status atual, medicação do dia, histórico de alertas e um gráfico de presença (leitura, somente exibição), além de formulários para cadastrar/editar medicamentos e compromissos (escrita). Acesso protegido por senha (`STREAMLIT_SENHA`), com uma tela de erro amigável em vez de stack traces para qualquer seção que falhe.

Seção	Captura de tela
Status atual	
Medicação do dia	
Histórico de alertas	

Seção	Captura de tela
Atividade de hoje (presença)	

3.6 Comunicação via WhatsApp (card 3.8)

A comunicação com o idoso e a família acontece via WhatsApp, integrada por meio do WAHA (WhatsApp HTTP API) — um webhook (`zela/api/webhook.py`) recebe mensagens recebidas pelo WAHA e as encaminha para o ADK Runner, que roteia ao agente apropriado; o cliente WAHA (`zela/integrations/waha_client.py`) envia as respostas de volta. Ver README para o passo a passo de configuração (Docker Compose + QR code + webhook).



---

4. Resultados obtidos

(Detalhamento completo — estratégia de testes, justificativa de cada decisão de design, cobertura por arquivo e o que fica fora da suíte automatizada — em `docs/testes/estrategia-e-resultados.md`.)

- 217 testes automatizados passando (`pytest -v`), cobrindo modelos Pydantic, lógica de domínio pura (rotina, monitoramento, emergência, comunicação), repositórios de armazenamento (SQLite), API (webhook, ingestão de sensores, classificação, scheduler),

embeddings (classificador, cliente, vector store), orquestração ADK (nomes, hierarquia de sub-agentes, ferramentas) e o painel Streamlit (via `streamlit.testing.v1.AppTest`, execução real do script sem mocks).
- Todo o projeto foi construído em 6 fases sequenciais (planos), cada uma testável e mergeada independentemente: Fundação → Comunicação Real → Ingestão de Sensores → Embeddings → Painel Streamlit → Workflow n8n — este relatório documenta a fase final (empacotamento).
- A propriedade de segurança central do projeto — nenhuma decisão de escalonamento de emergência depende de um LLM — foi verificada repetidamente ao longo das 6 fases (incluindo revisões de código dedicadas a cada mudança que tocasse essa fronteira).
- Exemplo prático de funcionamento: uma mensagem do idoso como "caí no banheiro e não consigo levantar", enviada via WhatsApp ou testada via o workflow n8n, é classificada como `RISCO` pelo classificador de embeddings e alimenta a mesma escada de escalonamento usada pelos sensores (ver seção 6 para uma limitação conhecida sobre esse fluxo).

---

5. Instruções de uso

Resumo rápido — o `README.md` do repositório tem o passo a passo completo (instalação, configuração do WAHA, sensores, Streamlit e n8n):

```
python -m venv .venv
source .venv/bin/activate
pip install -e ".[dev]"
pytest -v                               # roda a suíte de 217 testes
uvicorn zela.api.main:app --reload     # backend (webhook, API, scheduler)
streamlit run zela/streamlit_app/app.py  # painel da família
```

Para o comportamento real dos agentes (com chamadas de verdade ao Gemini), configuração do WAHA/WhatsApp, ingestão de sensores (Health Connect) e importação do workflow n8n, ver as seções correspondentes no `README.md`.

---

6. Limitações conhecidas e trabalhos futuros

Documentadas em detalhe no `README.md` ("Limitações conhecidas do Plano N"); resumo das mais relevantes:

1. Um risco originado por uma mensagem de texto não avança sozinho até a família — só o job periódico de sensores avança a escada de escalonamento adiante; corrigir exige persistir o evento que originou o escalonamento.
2. O classificador de urgência por similaridade não tem um piso mínimo de confiança — uma mensagem fora do padrão dos exemplos de referência ainda recebe a classificação do vizinho mais próximo.
3. Sessão de conversa do ADK Runner é única por idoso, não por remetente (idoso e família compartilham o mesmo histórico de contexto do LLM).
4. Autenticação por token nos endpoints `/ingest/*`, `/api/classificar-mensagem` e `/webhook/whatsapp` (header `X-Api-Key`, variável `ZELA_INGESTAO_TOKEN`) foi implementada, mas é opcional — sem a variável configurada, os endpoints continuam abertos (padrão de MVP em rede local). Nenhum exige autenticação por padrão até serem expostos fora da rede local. Atualização (deploy em VPS): `/webhook/whatsapp` inicialmente só tinha a allowlist de telefones/LID como defesa, que falha "aberta" (sem filtro) antes do primeiro perfil ser cadastrado — confirmado

na prática durante o deploy real, um POST forjado sem autenticação chegou a acionar o agente de IA de verdade. Corrigido para também exigir o token, igual aos outros endpoints.
5. Transcrição de áudio (STT/TTS) no WhatsApp ainda não implementada — hoje a comunicação é só por texto.
6. Sensor de presença via ESP32: o backend, o firmware e a documentação (diagrama elétrico, BOM, lógica de leitura) estão implementados e testados (`POST /ingest/esp32`, `zela/domain/monitoramento.py`), mas a validação com hardware físico não foi concluída nesta entrega — a placa física disponível (ESP32-S3) apresentou resets repetidos por watchdog (`TG1WDT_SYS_RST`/`TG0WDT_SYS_RST`) logo no boot, mesmo após isolar e descartar as causas de software mais prováveis (tamanho de flash, modo/frequência de flash, PSRAM, gravação corrompida — confirmada via verificação de hash byte a byte com `esptool`), o que aponta para um problema de hardware (alimentação, cabo ou placa) fora do escopo de diagnóstico remoto.

Hipótese de causa física: a placa usada já tinha alguns anos de uso/armazenamento antes deste projeto, e não apresentava esse comportamento anteriormente — a hipótese mais provável é oxidação em trilhas, pontos de solda ou nos pinos/contatos da placa (comum em ESP32 guardados por longos períodos sem uso, especialmente em ambientes úmidos), degradando conexões que antes funcionavam e causando os resets intermitentes por watchdog observados. Essa hipótese não foi testada de forma isolada (ex.: inspeção visual com microscópio, teste de continuidade ponto a ponto) porque está fora do escopo de diagnóstico remoto desta entrega — fica registrada como a explicação mais plausível, não como causa confirmada.

O monitoramento de risco desta entrega usa exclusivamente o smartwatch (Mi Band). 7. Limite de requisições do Gemini (tier gratuito) descoberto no deploy real: com uma `GOOGLE_API_KEY` do tier gratuito, o Gemini limita a 5 requisições/minuto — mandar várias mensagens de WhatsApp em sequência rápida (ex.: durante uma demonstração ao vivo) estoura essa cota, e o retry automático do cliente (`tenacity`, ~30s de espera por tentativa) deixa a resposta lenta a ponto de o proxy reverso (nginx) devolver 504 antes do backend terminar — confirmado na prática, não é só teórico. Mitigado em duas frentes: timeout do nginx aumentado para 180s, e o provedor de LLM de conversação trocado para DeepSeek (seção 3.3), que não tem esse limite. O Gemini continua em uso para embeddings (cota separada, não afetada) e fica disponível como reserva.

Essas limitações foram descobertas e documentadas durante o próprio desenvolvimento (revisões de código dedicadas ao final de cada fase), não depois da entrega — refletem prioridades conscientes de escopo de um MVP de 6 fases, não lacunas não percebidas.

---

7. Vídeo pitch

Roteiro cena a cena em `docs/pitch/roteiro.md`. Arquivo final em `docs/pitch/zela-pitch.mp4`.